AI RECEPT: DIDA BOŽA – OD INSTAGRAMA DO TRI GOTOVE OBJAVE
Autor: Matej Martinović
Datum: 28.10.2026.

NAPOMENA O TRANSPARENTNOSTI:
U ovom izvršavanju zadatka, vizuali su uspješno generirani pomoću AI alata za generiranje slika, a zatim su finalizirani u grafičkom alatu (dodavanje tipografije, teksta i vizualnog identiteta brenda). Detaljni promptovi koji su korišteni nalaze se u priloženom dokumentu Recept_i_Promptovi.txt.

1. UVOD I ODABIR BRENDA
Za demonstraciju je odabran brend Dida Boža (@dida_boza). Razlog je izuzetno prepoznatljiv vizualni identitet (topli, rustikalni, dalmatinski ugođaj) koji se izvrsno može replicirati AI alatima, uz jasnu "priču" o tradiciji i ekološkom uzgoju.
Korišteni izvori uključuju službenu web stranicu (didaboza.hr), stranicu proizvoda (Ekološki džem od smokve) i vizualne reference s Instagram profila. Provjereni podaci sa stranice potvrđuju ekološki uzgoj i BIO certifikat. Pretpostavke o ciljnoj publici (foodie scena, Slow Living) temelje se na vizualnom identitetu i tonu komunikacije brenda.

2. FAZE IZRADE I KORIŠTENI ALATI
- Brifing i analiza: Definirana je ciljna publika i ton (topao, edukativan, nostalgičan).
- Plan sadržaja: 3 objave – Karusel (edukacija i spremanje), Slika (interakcija i želja za proizvodom) i Reel (emocionalna povezanost).
- Alati: ChatGPT (za tekstove, planiranje i promptove), DALL-E 3 (za generiranje pozadine i ambijenta) te grafički alat za finalnu doradu (tipografija i brendiranje). Korištena je i Python skripta za automatizaciju generiranja sadržaja.

3. KLJUČNA KREATIVNA ODLUKA I LJUDSKA DORADA
Iako su AI alati odlični u generiranju atmosfere (svjetlo, teksture smokve i kruha), AI ne smije izmišljati etikete i ambalažu stvarnog brenda.
Planirana i izvršena dorada: AI je generirao savršenu mediteransku terasu s tanjurom i zdjelicom džema. S web stranice brenda preuzeta je stvarna staklenka, uklonjena joj je pozadina, te je ubačena u kadar uz dodavanje meke sjene kako bi se savršeno stopila s AI-generiranim izvorom svjetla. (Ova dorada je uspješno izvršena i vidljiva je na priloženim završnim vizualima).

4. OGRANIČENJA I UTROŠENO VRIJEME
- Vrijeme rada: Cijeli proces trajao je oko 1,5 sati aktivnog rada (uključujući generiranje, selekciju, testiranje skripte i finalno oblikovanje teksta na vizualima).
- Ograničenja: AI generirane slike ne mogu se koristiti kao vjerodostojan prikaz stvarnog pakiranja bez intervencije čovjeka. Za Reel je planirana tehnika spajanja statičnih slika (Ken Burns efekt) jer AI video alati još uvijek imaju problema s konzistentnošću tekstura hrane u pokretu.

5. PRIJEDLOG DALJNJEG UNAPREĐENJA (FEEDBACK LOOP)
Recept bi se mogao unaprijediti uvođenjem povratne sprege. Prikupili bismo podatke o angažmanu (lajkovi, spremanja, komentari) s prethodnih objava. AI bi te podatke koristio za prilagodbu sljedećih vizuala (npr. ako publika najviše sprema recepte, fokus sljedećeg karusela bio bi na kulinarskim koracima, a ne na

ambijentu).
Konkretne metrike koje bismo pratili uključuju: stopu spremanja (saves), broj komentara i doseg. Nova verzija bila bi bolja ako bi se A/B testiranjem (npr. svjetlija vs. tamnija pozadina) dokazalo da donosi veći broj interakcija i spremanja.

6. TEHNIČKA PROVJERA (PYTHON SKRIPTA)
Python skripta (generate_content.py) uspješno je testirana u --dry-run načinu rada, čime je potvrđeno da logika generiranja, struktura izlaza i spremanje datoteka rade ispravno bez trošenja API kredita. Dokaz testiranja nalazi se u datoteci primjer_izlaza_dry_run.txt na GitHub repozitoriju.